

# Uczenie modeli kanonicznych w sieciach Bayesowskich - efektywne uczenie modelu Noisy OR/MAX z danych.

Krzysztof Nowak

Politechnika Białostocka

23.10.2012

Sieć Bayesowska - struktura służąca do przedstawiania zależności pomiędzy zdarzeniami, bazując na rachunku prawdopodobieństwa.

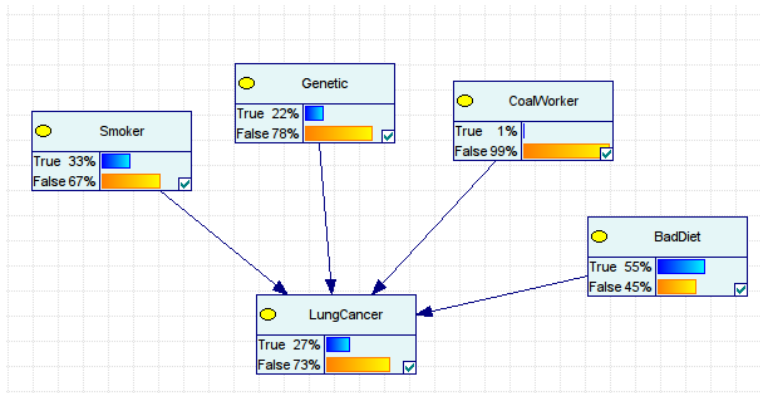
Sieć Bayesowska - struktura służąca do przedstawiania zależności pomiędzy zdarzeniami, bazując na rachunku prawdopodobieństwa. W sieciach bayesowskich można wyróżnić:

Sieć Bayesowska - struktura służąca do przedstawiania zależności pomiędzy zdarzeniami, bazując na rachunku prawdopodobieństwa. W sieciach bayesowskich można wyróżnić:

- Strukturę sieci - skierowany, acykliczny graf

Sieć Bayesowska - struktura służąca do przedstawiania zależności pomiędzy zdarzeniami, bazując na rachunku prawdopodobieństwa. W sieciach bayesowskich można wyróżnić:

- Strukturę sieci - skierowany, acykliczny graf
- Parametry sieci - wartości liczbowe określające prawdopodobieństwo poszczególnych zdarzeń



Rysunek: Przykładowa sieć bayesowska - Genie 2.0

## CPT - Conditional Probability Table

Node properties: LungCancer

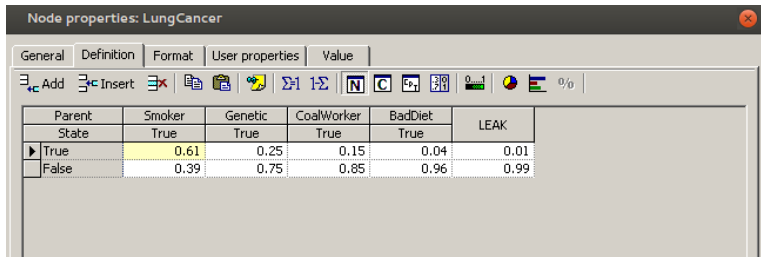
General Definition Format User properties Value

Add Insert

Smoker	<input type="checkbox"/>	True						
Genetic	<input type="checkbox"/>	True				False		
CoalWorker	<input type="checkbox"/>	True		False		True		False
BadDiet	<input type="checkbox"/>	True	False	True	False	True	False	True
True	<input checked="" type="checkbox"/>	0.7637068	0.75386125	0.722008	0.710425	0.6849424	0.671815	0.629344
False	<input type="checkbox"/>	0.2362932	0.24613875	0.277992	0.289575	0.3150576	0.328185	0.370656

Rysunek: CPT - Genie 2.0

- Wykładniczy przyrost parametrów ze względu na ilość węzłów rodzicielskich.
- Przydatny model przy uczeniu sieci z dużych zbiorów danych.



Parent State	Smoker	Genetic	CoalWorker	BadDiet	LEAK
True	0.61	0.25	0.15	0.04	0.01
False	0.39	0.75	0.85	0.96	0.99

Rysunek: Noisy MAX/OR - GeNIe 2.0

- Liniowy przyrost parametrów ze względu na ilość węzłów rodzicielskich.
- Przydatny model przy uczeniu sieci z małych zbiorów danych, bądź wiedzy eksperta.
- Bramka Noisy OR jest szczególnym przypadkiem bramki Noisy MAX.



# Modele kanoniczne - Noisy OR

- Najprostszy i najbardziej intuicyjny z modeli kanonicznych.

Bramka Noisy-OR wymaga podania prawdopodobieństwa wystąpienia danego zjawiska dla poszczególnych wartości węzłów rodzicielskich, niezależnie od pozostałych:

$$p_k = P(y|\bar{x}_1, \bar{x}_2, \dots, x_k, \dots, \bar{x}_{n-1}, \bar{x}_n). \quad (1)$$

Prawdopodobieństwo w bramce Noisy-OR przy wektorze wejściowym  $\mathbf{X}$  wyliczamy następująco:

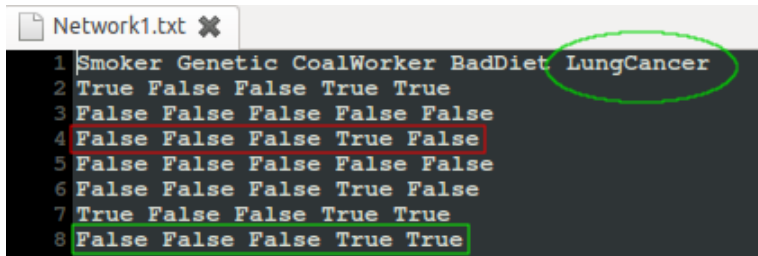
$$P(y|\mathbf{X}) = 1 - \prod_{i: x_i \in \mathbf{X}} (1 - p_i) \quad (2)$$

Parametr “LEAK” oznacza prawdopodobieństwo wystąpienia danego zjawiska, pomimo braku wystąpienia jakiegokolwiek jawnej przyczyny. Służy on do uwzględnienia tzw. niewymodelowanych przypadków:

$$p_{leak} = P(y|\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n). \quad (3)$$

# Wyliczanie parametrów z danych - CPT

Standardowy węzeł w sieci bayesowskiej wymaga podania całej tabeli prawdopodobieństw warunkowych. Zliczamy poszczególne wystąpienia danych kombinacji parametrów w pliku z danymi i na ich podstawie wyliczamy prawdopodobieństwo.



```
Network1.txt X
1 Smoker Genetic CoalWorker BadDiet LungCancer
2 True False False True True
3 False False False False False
4 False False False True False
5 False False False False False
6 False False False True False
7 True False False True True
8 False False False True True
```

Rysunek: Przykładowy plik z danymi

$$\frac{27}{27 + 311} = 0.079 \quad (4)$$

# Wyliczanie parametrów z danych - Noisy-OR/MAX

- Węzeł typu Noisy-OR/MAX nie wymaga podania prawdopodobieństwa dla każdej możliwej kombinacji parametrów, a jedynie dla prawdopodobieństwa wystąpienia każdego z parametrów z osobna (niezależnie od innych).
- Sposób wyliczania jest identyczny, jednak ze względu na charakter bramki Noisy-OR/MAX potrzebujemy znacznie mniej parametrów.

# Usprawnienie wyliczania parametrów z danych - Noisy-OR/MAX

- W podanym wcześniej pliku z danymi, ilość rekordów składających się na wyliczenie wszystkich parametrów dla bramki Noisy-OR to około **47%** wszystkich rekordów.
- Można to interpretować w taki sposób: Przy określaniu parametrów dla bramki Noisy-OR, pomijamy około **53%** informacji zawartych w danych.
- Dla porównania, określenie parametrów (CPT) dla bramki standardowej wykorzystuje cały plik z danymi.

# Usprawnienie wyliczania parametrów z danych - Noisy-OR/MAX

- W podanym wcześniej pliku z danymi, ilość rekordów składających się na wyliczenie wszystkich parametrów dla bramki Noisy-OR to około **47%** wszystkich rekordów.
- Można to interpretować w taki sposób: Przy określaniu parametrów dla bramki Noisy-OR, pomijamy około **53%** informacji zawartych w danych.
- Dla porównania, określenie parametrów (CPT) dla bramki standardowej wykorzystuje cały plik z danymi.
- Czy da się lepiej uzyskać poszczególne parametry sieci Noisy-OR ?

# Usprawnienie wyliczania parametrów z danych.

- Układy równań parametrów.

# Usprawnienie wyliczania parametrów z danych.

- Układy równań parametrów.
- Zamiast zliczać rekordy w danych określające każdy z parametrów bezpośrednio (Noisy-OR), wybieramy  $n$  kombinacji o największej liczbie “reprezentantów” w danych.

# Usprawnienie wyliczania parametrów z danych.

- Układy równań parametrów.
- Zamiast zliczać rekordy w danych określające każdy z parametrów bezpośrednio (Noisy-OR), wybieramy  $n$  kombinacji o największej liczbie “reprezentantów” w danych.
- Otrzymujemy w ten sposób pewien zbiór kombinacji parametrów, przykładowo:

$$x_1, \bar{x}_2, x_3, \bar{x}_4 = p_{1,3}$$

$$x_1, \bar{x}_2, \bar{x}_3, x_4 = p_{1,4}$$

$$\bar{x}_1, \bar{x}_2, x_3, x_4 = p_{3,4}$$

$$x_1, x_2, x_3, \bar{x}_4 = p_{1,2,3}$$



# Usprawnienie wyliczania parametrów z danych.

- Układy równań parametrów.
- Zamiast zliczać rekordy w danych określające każdy z parametrów bezpośrednio (Noisy-OR), wybieramy  $n$  kombinacji o największej liczbie "reprezentantów" w danych.
- Otrzymujemy w ten sposób pewien zbiór kombinacji parametrów, przykładowo:  
$$x_1, \bar{x}_2, x_3, \bar{x}_4 = p_{1,3}$$
$$x_1, \bar{x}_2, \bar{x}_3, x_4 = p_{1,4}$$
$$\bar{x}_1, \bar{x}_2, x_3, x_4 = p_{3,4}$$
$$x_1, x_2, x_3, \bar{x}_4 = p_{1,2,3}$$
- Zależy nam na uzyskaniu parametrów  $p_1, p_2, p_3, p_4$ .

- Korzystając ze wzoru (2) mamy:

$$1 - (1 - p_1) \times (1 - p_3) = p_{1,3}$$

$$1 - (1 - p_1) \times (1 - p_4) = p_{1,4}$$

$$1 - (1 - p_3) \times (1 - p_4) = p_{3,4}$$

$$1 - (1 - p_1) \times (1 - p_2) \times (1 - p_3) = p_{1,2,3}$$

- Korzystając ze wzoru (2) mamy:

$$1 - (1 - p_1) \times (1 - p_3) = p_{1,3}$$

$$1 - (1 - p_1) \times (1 - p_4) = p_{1,4}$$

$$1 - (1 - p_3) \times (1 - p_4) = p_{3,4}$$

$$1 - (1 - p_1) \times (1 - p_2) \times (1 - p_3) = p_{1,2,3}$$

- Aby uprościć obliczenia, rozwiążemy układ dla  $1 - p_i$  zamiast  $p_i$  (używamy podstawienia  $p'_i = 1 - p_i$ ).

- Korzystając ze wzoru (2) mamy:

$$1 - (1 - p_1) \times (1 - p_3) = p_{1,3}$$

$$1 - (1 - p_1) \times (1 - p_4) = p_{1,4}$$

$$1 - (1 - p_3) \times (1 - p_4) = p_{3,4}$$

$$1 - (1 - p_1) \times (1 - p_2) \times (1 - p_3) = p_{1,2,3}$$

- Aby uprościć obliczenia, rozwiążemy układ dla  $1 - p_i$  zamiast  $p_i$  (używamy podstawienia  $p'_i = 1 - p_i$ ).

$$1 - (p'_1) \times (p'_3) = p_{1,3}$$

$$1 - (p'_1) \times (p'_4) = p_{1,4}$$

$$1 - (p'_3) \times (p'_4) = p_{3,4}$$

$$1 - (p'_1) \times (p'_2) \times (p'_3) = p_{1,2,3}$$

- Ostatecznie otrzymujemy:

$$(p'_1) \times (p'_3) = 1 - p_{1,3}$$

$$(p'_1) \times (p'_4) = 1 - p_{1,4}$$

$$(p'_3) \times (p'_4) = 1 - p_{3,4}$$

$$(p'_1) \times (p'_2) \times (p'_3) = 1 - p_{1,2,3}$$

- Nie jest to liniowy układ równań.

① Rozwiązanie za pomocą zmodyfikowanej eliminacji gaussa.

② Zlogarytmować obustronnie każde z równań.

$$\log(p'_1) + \log(p'_3) = \log(1 - p_{1,3})$$

$$\log(p'_1) + \log(p'_4) = \log(1 - p_{1,4})$$


$$\log(p'_3) + \log(p'_4) = \log(1 - p_{3,4})$$

$$\log(p'_1) + \log(p'_2) + \log(p'_3) = \log(1 - p_{1,2,3})$$


# Rozwiązywanie układu równań

- Uzyskane w ten sposób parametry  $p_i'' = \log(p_i')$  dają nam szukane parametry  $p_i$  przez ponowne podstawienie:  
 $p_i = 1 - e^{p_i''}$ , gdzie  $e$  - podstawa logarytmu (dowolna)
- Rozwiązanie samego układu nie stanowi problemu
- Wybór odpowiednich równań jest kluczowy - Równania muszą być liniowo niezależne
- Sam wybór stanowi o skuteczności ostatecznego rozwiązania:
  - 1 Optymalizacja sumarycznej ilości “reprezentatów” w układzie równań.
  - 2 Rozwiązanie  $n$  układów, rozpatrując każdy z parametrów z osobna.
  - 3 Rozwiązanie  $m$  układów równań, i wyliczenie  $m$  zestawów parametrów, z których wyliczamy ostateczny zestaw parametrów za pomocą średniej ważonej.

Przydatna będzie heurystyka wyboru równań uwzględniającą ich liniową niezależność. Dokładne rozwiązanie może być złożone  $\binom{2^n}{n}$ .




Rysunek: Średni błąd parametru




Rysunek: Maksymalny błąd parametru

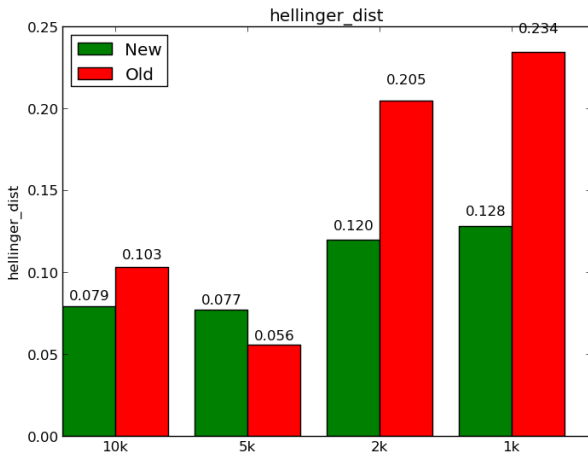




Rysunek: Odległość euklidesowa.



Rysunek: Dywergencja Kullbacka-Leiblera.



Rysunek: Odległość Hellingera.

- Francisco J. Diez, Marek J. Drużdżel - "Canonical Probabilistic Models for Knowledge Engineering" (28.4.2007)
- Nir Friedman, Moises Goldszmidt - "Learning Bayesian networks with local structure"
- Agnieszka Oniśko, Marek J. Drużdżel, Hanna Wasyluk - "Learning Bayesian network parameters from small data sets: application of Nosi-OR gates" (1.3.2001)